KC-Safe-MAPPO 方法具体实现总结

在这个项目中，KC-Safe-MAPPO（领域知识约束增强的安全多智能体近端策略优化）方法的核心在于**将化工领域知识（Domain Knowledge）和硬约束（Hard Constraints）优雅地嵌入到强化学习的训练与执行环节中**。具体可以拆解为以下四个维度的实现：

1. 安全动作掩码层 (Safe Action Masking) —— `marl/envs/safety_layer.py`

传统 RL 在面对强约束问题时，往往依赖惩罚函数（Reward Penalty）让智能体慢慢试错，这在拥有严格物料平衡和储罐容量限制的炼厂中效率极低。

- **具体实现**：引入了 `SafetyLayer` 类。在每一时间步 t，针对每一个装置（Agent，如 CDU1、FCC），该层会基于当前的上下游库存（Inventories）和装置的处理能力，前向推演计算出合法的负荷范围。
- **物理意义**：比如，如果下游的 `naphtha_buffer` 即将满载，或者上游的原油不足，安全层会将其对应的“高负荷”动作的 Mask 置为 0。
- **算法集成**：在 Actor 神经网络的最后一层输出后，直接与这个 `action_mask` 相乘，把非法动作的概率强制降为零。这保证了智能体探索出的每一步都是（或极高概率是）符合物理定律的。

2. 领域知识启发式防御 (Knowledge-driven Profit Guard) —— `marl/experiments/compare_uncertainty_methods.py`

纯数据驱动的 MAPPO 有时会在罕见的极端市场波动下（如原油价格暴涨）依然维持原有高产模式。

- **具体实现**：项目中实现了一个 `apply_profit_guard` 函数。这是一个轻量级的领域知识钩子（Hook）。在模型推理出动作后，该引擎会实时对比当前的原油价格乘数与平均产品价格乘数。
- **规则干预**：如果发现原油成本明显高于产品收益，安全网会主动介入，将上游核心装置（CDUs）的推荐高负荷强制下调一档。这赋予了模型面对未见过的极端环境时的“兜底安全能力”。

3. 去中心化执行与集中式训练架构 (CTDE MARL) —— `marl/algorithms/kc_safe_mappo.py`

炼厂包含多个互相关联的装置，如果用单智能体控制，动作空间会呈指数级爆炸。

- **Actor (局部执行者)：采用参数共享（Parameter Sharing）**的 Actor 网络。每个装置只需观察自己的局部信息（相连上下游的库存、直接需求），拼接上自身的 `agent_id`（One-hot 编码），独立输出自己的负荷调整决策。这极大降低了动作空间的维度。
- **Critic (全局评价者)：在训练阶段，Critic 网络能够“开启上帝视角”，输入的是全厂的全局状态（Global State）**，包括所有缓冲罐的物料液位、所有产品的实时需求和市场价格。Critic 利用全局信息为局部的 Actor 提供极其精准的优势函数（Advantage）指导，评估当前的联合动作对全厂总利润的贡献。

4. 经济导向与动态退火训练 (Economics-aligned Reward) —— `marl/envs/reward.py`

- **全生命周期经济函数**：Reward 的计算并非简单的“产出越多越好”，而是精确对齐了 Gurobi MILP 模型的财务逻辑。奖励被定义为：`Profit = Revenue - Crude Cost - Energy Cost - Switch Cost - Inventory Penalty`。这种设计使得智能体必须在“多产出带来高收入”和“过度采购原油/积压库存带来高惩罚”之间寻找博弈平衡点。
- **Entropy 与学习率退火**：在训练循环中实现了线性退火策略。训练初期给子智能体较高的 Entropy Coefficient（强制探索不同的负荷组合），在训练后期逐步将 Entropy 和学习率降至 10%，促使模型在找到较好策略后向微观的最优负荷精细收敛，从而达到理论最优 MILP 利润的近 80%。

💡 核心总结

KC-Safe-MAPPO 的本质是：**用运筹学物理模型（安全层）限制探索边界，用先验行业经验（Profit Guard）保障极端情况底线，最终用多智能体强化学习（MAPPO）在合法的边界内高速搜索出经济效益最高的联合调度策略。** 这种将机理与数据融合的设计，正是它能快速收敛并适用于动态不确定环境的根本原因。